

제목	혐오는 어떻게 남아 재생산되는가?
문제 제기	본 연구는 한국 사회에서 혐오가 어떤 형태로 남고 재생산되는지를 살펴본다. 우리는 흔히 혐오를 미워하는 마음, 즉 개인의 감정으로 이해해왔다. 그러나 혐오는 개인의 감정에 그치지 않는다. 사회적 갈등 속에서 반복적으로 인식되고, 온라인 언어 안에 남으며, AI 학습 과정에도 영향을 줄 수 있다. 이에 “혐오는 어떻게 남아 재생산되는가?”를 묻는다. 이 질문은 누가 많이 공격받는가보다, 혐오가 어떤 규칙과 구조를 통해 남는가에 초점을 둔다. 구체적으로 사회에서 인식되고 경험된 혐오가 온라인 언어 안에서 어떤 반복 양식으로 나타나는지, 그리고 그러한 언어적 구조가 AI 모델 안에 학습된 연관으로 남을 수 있는지를 탐색한다.
데이터 선택과 분석	혐오가 사회, 언어, AI의 세 층위에서 어떤 형태로 남는지를 보기 위해 모두 이미 수집·공개된 2차 자료를 활용하였다. 분석 자료를 직접 수집하거나 새로 라벨링하지 않았으며, 기존 조사 자료와 공개 데이터셋, 공개 모델을 바탕으로 분석을 수행하였다. 사회적 층위에서는 한국행정연구원의 「사회통합실태조사」와 국가인권위원회의 「인권의식실태조사」를 활용하였다. 이를 통해 한국 사회의 갈등 인식과 혐오표현 접촉 경험을 확인하였다. 언어적 층위에서는 KOLD(Korean Offensive Language Dataset)를 활용하였다. KOLD는 NAVER 뉴스와 YouTube의 한국어 댓글 40,429개로 구성된 혐오표현 데이터셋이다. 본 연구에서는 데이터를 새로 수집하거나 주석하지 않고, 기존 라벨링 중 표적 집단과 공격 표현 정보를 이용하였다. 표적별로 과도하게 반복되는 변별어를 찾기 위해 log-odds 분석을 수행하였고, 한 댓글 안에서 여러 집단이 함께 공격되는 양상을 보기 위해 공동 표적 네트워크를 구성하였다. 네트워크에서는 표적 집단을 노드로, 함께 공격된 관계를 엣지로 설정하였다. 이후 매개중심성을 통해 서로 다른 혐오 표적들을 이어주는 집단이 무엇인지 분석하였다. AI 층위에서는 한국어 코퍼스 기반 공개 모델인 KLUE-RoBERTa와 fastText를 활용하였다. 표적 집단이 AI의 의미공간에서 긍정어보다 부정어에 더 가깝게 위치하는지 보기 위해 WEAT 기반 연관 분석을 수행하였다. 또한 “○○은 __다”와 같은 문장의 빈칸을 채우게 하여 특정 집단에 대해 부정어가 생성되는지도 확인하였다. 이를 통해 혐오가 감정이나 직접 경험 없이도 학습된 언어적 연관으로 남을 가능성을 탐색하였다.

데이터분석 주요 결과와 설명	첫째, 혐오는 한국 사회에서 인식되고 경험되는 현상으로 나타났다. 사회통합실태 조사와 인권의식실태조사 분석 결과, 사람들은 여러 갈등 축을 심각하게 인식하고 있었고 절반 이상이 지난 1년 내 혐오표현을 접촉한 경험이 있었다. 특히 혐오표현 접촉의 70.3%는 온라인에서 이루어졌다. 이는 혐오가 개인의 감정에만 머무르지 않고, 사회적으로 반복 경험되는 문제임을 보여준다. 둘째, 온라인 언어 속 혐오는 부정형의 감정 분출이 아니라 반복되는 양식으로 나타났다. KOLD 댓글의 변별어를 분석한 결과, 표적별 공격 표현은 위협·추방, 병리화, 오염, 조롱, 침묵 요구 등 몇 가지 양식으로 수렴했다. 같은 표현 양식은 표적을 넘나들며 재사용되었다. 혐오는 집단별로 고립된 표현이 아니라, 공유되는 공격 문법으로 남아 있었다. 셋째, 혐오의 표적들은 서로 독립적으로 존재하지 않고 공동 표적 네트워크 안에서 연결되어 있었다. 네트워크 분석 결과, 여성 표적은 여러 갈등 축을 잇는 중심 위치에 있었고 매개중심성도 가장 높았다. 반면 남성은 많이 공격받는 표적이지만 매개중심성은 낮았다. 많이 공격받는 것과 서로 다른 혐오가 만나는 자리에 있는 것은 달랐다. 넷째, AI 분석에서는 표적 집단들이 부정적 의미공간에 더 가깝게 위치하는 양상이 확인되었다. WEAT와 빈칸 채우기 분석 결과, 표적 집단은 부정어와 더 강하게 연결되거나 부정어로 예측되는 경향을 보였다. 특히 흑인은 한국 내 비율이 매우 낮고 자생적 비하어도 두드러지지 않았음에도 부정 연관이 크게 나타났다. 혐오는 직접 경험이나 감정 없이도, 온라인 텍스트를 통해 학습된 연관으로 AI 안에 남을 수 있다.
토의	본 연구는 “혐오는 어떻게 남아 재생산되는가?”라는 질문에서 출발하였다. 사회조사 자료는 혐오가 한국 사회에서 인식되고 경험되는 현상임을 보여주었다. KOLD 댓글 자료는 그 혐오가 온라인 언어 안에서 반복되는 표현 양식과 공동 표적 구조로 남아 있음을 보여주었다. AI 모델 분석은 이러한 언어적 구조가 부정적 의미 연관으로 학습될 수 있음을 보여주었다. 따라서 혐오는 감정의 문제만이 아니라 재생산의 문제이다. 분노는 식지만, 문법은 남는다. 한 번 쓰인 말은 온라인 언어 속에 남고, AI는 그 언어를 학습한다. AI는 감정도 의도도 없지만, 반복된 연관을 배운다. 이 점에서 개입의 자리도 달라진다. 혐오가 채널과 모델 안에서 복제된다면, 문제는 삭제만이 아니라 학습 설계의 문제이기도 하다. 지워도 남을 수 있고, 부정해도 함께 등장한 단어의 연관은 강화될 수 있다. 본 연구는 ‘누가 많이 공격받는가’보다 ‘어떤 규칙으로 짜이는가’를 보았다. 사회에서는 갈등과 혐오의 실재를, 언어에서는 반복되는 문법과 표적 구조를, AI에서는 학습된 연관의 가능성을 확인하였다. 다음 세대의 언어 모델에게 무엇을 받아쓰게 할 것인가. 그 선택은 지금 우리에게 남아 있다.